

Manifiesto de Entrega — Versión Beta

Imputación Generativa de Datos Hidrometeorológicos
Red CONAGUA-SMN · 173 Estaciones · Sinaloa, México

US 5.3 | RES-133
Fecha: 16 de mayo de 2026 | Versión: Beta 1.0

Autores: José Ángel García Pérez · Sebastián Verdugo Bermúdez
Asesores: Dr. Jesús Gabriel Rangel Peraza · Dr. Zuriel Dathan Mora Félix

Manifiesto de Entrega — Versión Beta

Descripción del sistema

El presente documento lista todos los componentes del paquete de entrega de la versión beta del **sistema de imputación generativa hidrometeorológica** para 173 estaciones de la red CONAGUA-SMN en Sinaloa. El sistema implementa el pipeline CRISP-ML(Q) en 10 etapas automatizadas, con el modelo BiGRU-opt como núcleo de imputación (NSE global = 0.621, cobertura de imputación = 99.8%).

Artefacto principal de salida: data/imputed/dataset_imputado.parquet

1,611,118 registros · 173 estaciones · 4 variables (precip, evap, tmax, tmin) · escala original (mm, °C)

1. Scripts del pipeline

1.1 Orquestador

Archivo	Descripción
Pipeline Reproducible/run_pipeline.py	Ejecuta las 10 etapas en orden verificando salidas intermedias
Pipeline Reproducible/config.yaml	Define etapas, scripts, rutas y artefactos de verificación

Ejecución completa:

```
python "Pipeline Reproducible/run_pipeline.py"
```

Ejecución parcial (etapas 8-10, asumiendo etapas 1-7 completadas):

```
python "Pipeline Reproducible/run_pipeline.py" --from-stage 8

# O individualmente:
python "Quality Gate/quality_gate.py"
python "Imputación Generativa/impute.py"
python "Validación Estadística/validate_imputation.py"
```

1.2 Scripts por etapa

Etap	Script	Entrada principal	Salida verificable
1	Obtencion de Datos Crudos/download_sinaloa_raw_pro.py	API CLICOM	data/raw/

Etapas	Script	Entrada principal	Salida verificable
2	Estructuración del Dataset/organize_raw_by_station_year_variable_parquet.py	data/raw/	data/interim/
3	Validación y limpieza/cleaning.py	data/interim/	data/cleaned/
4	Preprocesamiento/normalize.py	data/cleaned/	models/scalers/*.pkl
5	Dataset Final Procesado/pipeline.py	data/cleaned/ + scalers	data/processed/dataset_final.parquet
6	División Train-Val-Test/split.py	dataset_final.parquet	data/splits/
7	Construcción de Tensores/tensor_builder.py	data/splits/	data/tensors/
8	Quality Gate/quality_gate.py	dataset_final.parquet	reports/quality_gate/quality_gate_report.pdf
9	Imputación Generativa/impute.py	dataset_final.parquet	data/imputed/dataset_imputado.parquet
10	Validación Estadística/validate_imputation.py	dataset_final + dataset_imputado	reports/validacion_estadistica/

Las etapas 8, 9 y 10 son las nuevas etapas entregadas en la versión beta (US 5.3).

2. Archivos de configuración

Archivo	Etapas	Parámetros clave
Pipeline Reproducible/config.yaml	Orquestador	10 etapas, rutas, artefactos de verificación
Quality Gate/config.yaml	8	Límites físicos, umbrales de faltantes, KPSS
Imputación Generativa/config.yaml	9	Arquitectura BiGRU-opt, scalers, ventanas, semilla
Validación Estadística/config.yaml	10	Entradas, salidas, significancia KS/KPSS
Validación y limpieza/config.yaml	3	Reglas de limpieza, límites físicos (fuente de verdad)
Preprocesamiento/config.yaml	4	Tipo de escalador por variable
Construcción de Tensores/config.yaml	7	Ventana = 30 días, stride = 7 (debe coincidir con impute.py)

3. Artefactos del modelo

3.1 Checkpoint del modelo ganador

Archivo	Tamaño	Descripción
models/optimizacion/bigru_opt.pt	1.6 MB	Checkpoint PyTorch — BiGRU-opt (hidden = 128, layers = 2, dropout = 0.103)

Hiperparámetros óptimos (Optuna TPE, 50 trials):

Hiperparámetro	Valor óptimo
hidden_size	128
n_layers	2
dropout	0.103
learning_rate	1.9×10^{-3}
batch_size	128
window_size	30 días

3.2 Scalers de normalización

Archivo	Variable	Tipo	Parámetros
models/scalers/scaler_precip.pkl	precip	MinMaxScaler [0, 1]	min = 0.0, max = 500.0
models/scalers/scaler_evap.pkl	evap	MinMaxScaler [0, 1]	min = 0.0, max = 60.0
models/scalers/scaler_tmax.pkl	tmax	StandardScaler	$\mu = 32.67\text{ }^{\circ}\text{C}$, $\sigma = 4.90$
models/scalers/scaler_tmin.pkl	tmin	StandardScaler	$\mu = 16.71\text{ }^{\circ}\text{C}$, $\sigma = 6.21$
models/scalers/scalers_metadata.csv	—	Metadatos	Parámetros completos de todos los scalers

3.3 Selección del modelo ganador

Archivo	Descripción
reports/optimizacion/seleccion_ejecutiva.csv	Leído en tiempo de ejecución por <code>impute.py</code> para selección dinámica del ganador
reports/optimizacion/seleccion_modelo_ganador.pdf	Reporte técnico completo (19 pp.) — metodología MCDM y justificación de selección

Nota importante: `dataset_final.parquet` está en escala normalizada (salida de `normalize.py`). Los scripts de etapas 8, 9 y 10 aplican `inverse_transform` internamente antes de verificaciones físicas y antes del procesamiento del modelo. El dataset imputado de salida está en escala original (mm, °C).

4. Datos

4.1 Datos de entrada requeridos

Archivo	Tamaño	Descripción
data/processed/dataset_final.parquet	8.7 MB	Dataset normalizado — 1,611,118 filas, 173 estaciones, 4 variables

4.2 Datos de salida generados

Archivo	Tamaño	Descripción
data/imputed/dataset_imputado.parquet	16 MB	Dataset imputado en escala original (mm, °C)
data/imputed/dataset_imputado.csv	—	Copia CSV del dataset imputado

Estadísticas de cobertura:

Variable	NaN originales	Rellenados	Residuales	Cobertura
precip	10,858	10,811	47	99.6%
evap	623,106	622,268	838	99.9%
tmax	113,162	112,942	220	99.8%
tmin	113,162	112,942	220	99.8%
Total	860,288	858,963	1,325	99.8%

5. Reportes generados

Archivo	Etap	Contenido
reports/quality_gate/quality_gate_report.csv	8	Criterios críticos y advertencias pre-imputación
reports/quality_gate/_logs/quality_gate_run.log	8	Log completo de ejecución
reports/imputacion/imputacion_report.csv	9	NaN rellenados por variable y estación
reports/imputacion/_logs/	9	Log de imputación
reports/validacion_estadistica/metricas_imputacion.csv	10	Cobertura de imputación por variable
reports/validacion_estadistica/ks_test_report.csv	10	KS-test distribución observada vs. imputada
reports/validacion_estadistica/correlaciones_comparativas.csv	10	Correlaciones inter-variable antes/después
reports/validacion_estadistica/_logs/	10	Log completo de validación
reports/beta/beta_test_results.md	—	Resultados de pruebas funcionales (RES-132)
reports/beta/validacion_criterios_aceptacion.md	—	Validación de criterios de aceptación (RES-134)
reports/beta/paquete_entrega_beta.md	—	Este documento (RES-133)

6. Documentación

Documento	Descripción
README.md	Visión general del pipeline, instalación, quick start
Pipeline Reproducible/README.md	Uso del orquestador, flags, tabla de 10 etapas
Imputación Generativa/README.md	Arquitectura BiGRU-opt, parámetros, criterios de aceptación

7. Dependencias

```
Python >= 3.10

torch >= 2.0          # modelo BiGRU-opt
pandas >= 2.0
numpy >= 1.24
pyarrow >= 12.0       # lectura/escritura parquet
scikit-learn >= 1.3   # MinMaxScaler, StandardScaler
pyyaml >= 6.0         # configuración YAML
scipy >= 1.11         # ks_2samp (KS-test)
statsmodels >= 0.14   # kpss
tqdm >= 4.65         # progreso
```

Hardware mínimo: 4 GB RAM, 2 GB almacenamiento libre. GPU no requerida (etapa 9 completada en 42.8 s en CPU).

8. Verificación rápida del resultado

```
import pandas as pd

df = pd.read_parquet("data/imputed/dataset_imputado.parquet")
print(f"Filas      : {len(df):,}") # esperado: 1,611,118
print(f"Estaciones  : {df['estacion'].nunique():}") # esperado: 173
print(f"NaN residuales: {df[['precip', 'evap', 'tmax', 'tmin']].isna().sum().sum():}") # esperado: < 1,325
```

9. Checklist de componentes del paquete

Componente	Tamaño	Estado
Pipeline Reproducible/run_pipeline.py	—	SI
Quality Gate/quality_gate.py + config.yaml	—	SI
Imputación Generativa/impute.py + config.yaml	—	SI
Validación Estadística/validate_imputation.py + config.yaml	—	SI
models/optimizacion/bigru_opt.pt	1.6 MB	SI
models/scalers/scaler_*.pkl (4 archivos)	—	SI
reports/optimizacion/seleccion_ejecutiva.csv	—	SI
data/processed/dataset_final.parquet	8.7 MB	SI
data/imputed/dataset_imputado.parquet	16 MB	SI
reports/quality_gate/quality_gate_report.csv	—	SI
reports/validacion_estadistica/metricas_imputacion.csv	—	SI
reports/beta/beta_test_results.md	—	SI
reports/beta/validacion_criterios_aceptacion.md	—	SI
README.md	—	SI

Estado del paquete: COMPLETO — todos los componentes presentes y verificados.