

Documento de Arquitectura de Software (DAS)

Proyecto: Reconstrucción de una base de datos hidrometeorológica a partir de técnicas de Inteligencia Artificial

Laboratorio de Geomática y Teledetección

Control de cambios

Versión	Descripción del cambio	Autor	Aprobado por	Fecha de aprobación
1.0	Creación inicial del documento	Sebastián Verdugo Bermúdez	—	27 de enero de 2026
2.0	Diagrama L1	Sebastian Verdugo Bermúdez - José Angel García Pérez	—	28 de enero de 2026
3.0	Correcciones del Sprint 1 y Añadiendo partes del Sprint 2	Sebastian Verdugo Bermúdez - José Angel García Pérez	—	05 de febrero de 2026
4.0	Correcciones dle Spirnt 2Añadiendo partes del Sprint 3	Sebastian Verdugo Bermúdez - José Angel García Pérez	—	23 de febrero de 2026

Índice

Contenido

CAPITULO I INTRODUCCIÓN	1
A. Contexto General.....	2
B. Contexto del Problema	2
C. Enfoques de Inteligencia Artificial para Reconstrucción.....	3

D. Justificación del Proyecto	3
II. OBJETIVOS	4
A. Objetivo General	4
B. Objetivos Específicos	4
III. ALCANCE, SUPUESTOS Y LIMITACIONES	4
A. Alcance	5
B. Supuestos	5
C. Limitaciones	5
IV. CRITERIOS DE ÉXITO	5
CAPÍTULO II MARCO TEÓRICO	5
A. Series Temporales Hidrometeorológicas	6
B. Desafíos Específicos de Datos Hidrometeorológicos	6
C. Fundamentos Estadísticos de Series Temporales	7
1) Estacionariedad	7
2) Modelo ARIMA y SARIMA	7
3) Modelos ETS	7
D. Datos Faltantes: Marco Teórico	7
E. Métodos Tradicionales de Imputación	8
1) Interpolación Lineal	8
2) Regresión Múltiple	8
3) K-Nearest Neighbors (KNN)	8
4) Expectation-Maximization (EM)	8
5) Multiple Imputation	8
F. Limitaciones Estructurales de Modelos Lineales	9
G. Técnicas de Inteligencia Artificial	9
1) LSTM	9
2) Autoencoders	9
3) GAN y BRITS	9
4) Modelos de Difusión	10
H. Comparación Tradicional vs Deep Learning	10
I. Métricas de Evaluación	10
J. Metodologías de Ciencia de Datos	10

K. Arquitectura de Pipelines.....	11
Conclusión del Marco Teórico	11
CAPÍTULO III METODOLOGÍA DE LA INVESTIGACIÓN	11
A. Enfoque metodológico de la investigación	11
B. Metodología seleccionada: CRISP-ML(Q).....	12
C. Fases del proyecto bajo CRISP-ML(Q)	13
1) Comprensión del problema	13
2) Comprensión de los datos.....	14
3) Preparación de los datos.....	14
4) Modelado.....	15
5) Evaluación y Quality Gate.....	16
6) Despliegue y arquitectura.....	17
7) Monitoreo y mantenimiento.....	18
D. Síntesis metodológica y alineación con el proyecto	19
CAPÍTULO IV DISEÑO Y ARQUITECTURA DEL SISTEMA.....	19
A. Requerimientos del sistema	19
1) Requerimientos funcionales	19
2) Decisiones arquitectónicas y Estilo.....	21
3) Arquitectura Conceptual.....	22
4) Arquitectura Lógica.....	23
5) Arquitectura Física y Stack Tecnológico.....	29
6) Modelo de Datos (Diagrama Entidad-Relación)	30
7) Suposiciones y restricciones arquitectónicas	31
8) Cierre del capítulo	31
5. Glosario: definiciones, siglas y abreviaturas	31
6. Conclusiones generales del documento.....	32
Bibliografía	32

CAPITULO I INTRODUCCIÓN

A. Contexto General

La información hidrometeorológica constituye un insumo fundamental para la modelación hidrológica, la evaluación de recursos hídricos, el análisis climático y la

gestión de riesgos ambientales. Variables como precipitación, temperatura, humedad relativa y evaporación permiten estudiar la dinámica atmosférica e hidrológica y son esenciales para el análisis de disponibilidad de agua y eventos extremos [1].

En México, instituciones como la Comisión Nacional del Agua (CONAGUA) y el Servicio Meteorológico Nacional (SMN) generan registros históricos provenientes de estaciones meteorológicas distribuidas en el territorio nacional. Estos registros son utilizados en estudios académicos, análisis ambientales y planeación territorial. Sin embargo, las bases de datos hidrometeorológicas presentan con frecuencia valores faltantes, inconsistencias y discontinuidades temporales derivadas de fallas instrumentales, mantenimiento de estaciones, interrupciones operativas o errores en la transmisión y almacenamiento de la información.

La literatura especializada en aseguramiento de calidad hidrometeorológica señala que la validación del dato debe acompañarse de mecanismos formales de trazabilidad. Branisavljević et al. establecen que: “Every validated and sometimes improved data value is accompanied with a meta-data that holds its validation grade as a quality indicator for further use” [2, p. 6].

Este enfoque resalta que la reconstrucción de datos no debe limitarse a sustituir valores faltantes, sino que debe garantizar consistencia estadística, coherencia física y documentación del proceso de validación.

Adicionalmente, estudios recientes sobre calidad y limpieza de datos enfatizan que el preprocesamiento constituye una etapa crítica en cualquier sistema analítico. Alotaibi et al. afirman que: “Data cleaning plays a major role in increasing data quality and improving the reliability of analytical outcomes” [3, p. 3].

En el caso de series temporales ambientales, la presencia de estacionalidad, autocorrelación y relaciones multivariantes incrementa la complejidad del tratamiento de datos incompletos [4].

B. Contexto del Problema

Las bases de datos hidrometeorológicas históricas presentan discontinuidades que afectan la confiabilidad del análisis estadístico y el desempeño de modelos predictivos. La ausencia de datos completos puede introducir sesgos en la detección de tendencias, distorsionar la estimación de extremos y comprometer la capacidad de generalización de modelos de aprendizaje automático.

Desde el punto de vista estadístico, los datos faltantes pueden clasificarse como completamente aleatorios (MCAR), aleatorios condicionados (MAR) o no aleatorios (MNAR), de acuerdo con el marco teórico propuesto por Rubin [5] y desarrollado posteriormente por Little y Rubin [6]. En registros hidrometeorológicos, los valores

faltantes suelen estar asociados a condiciones operativas específicas o eventos extremos, lo que incrementa la complejidad del proceso de imputación.

Los métodos tradicionales de imputación, tales como interpolación lineal o promedios históricos, no modelan adecuadamente dependencias temporales de largo plazo ni relaciones no lineales entre variables. Asimismo, la modelación clásica de series temporales, como los enfoques ARIMA descritos por Box y Jenkins [7], requiere supuestos de estacionariedad que pueden verse comprometidos ante datos incompletos.

Hyndman y Athanasopoulos destacan que el análisis adecuado de series temporales requiere preservar estructura temporal, tendencia y estacionalidad para garantizar coherencia estadística [4].

C. Enfoques de Inteligencia Artificial para Reconstrucción

En los últimos años, las técnicas de aprendizaje profundo han demostrado una capacidad superior para modelar dependencias complejas en series temporales con datos faltantes.

El modelo BRITS (Bidirectional Recurrent Imputation for Time Series) propone aprender directamente los valores faltantes dentro de un sistema recurrente bidireccional, sin imponer supuestos rígidos sobre la estructura del dato. Sus autores señalan: “Our proposed method directly learns the missing values in a bidirectional recurrent dynamical system, without any specific assumption” [8, p. 1].

Asimismo, los modelos generativos adversariales aplicados a series temporales multivariantes permiten capturar la distribución conjunta de las variables. Luo et al. proponen un marco basado en GAN para imputación multivariante [9], demostrando mejoras frente a métodos tradicionales en métricas como RMSE y MAE.

Estos enfoques resultan particularmente adecuados para datos hidrometeorológicos de largo plazo y naturaleza multivariante, donde la dependencia entre variables (por ejemplo, temperatura y precipitación) juega un papel relevante.

D. Justificación del Proyecto

La reconstrucción confiable de una base de datos hidrometeorológica es esencial para garantizar análisis ambientales robustos y decisiones técnicas fundamentadas.

Desde el punto de vista metodológico, la comparación entre modelos clásicos de series temporales y modelos de aprendizaje profundo permite evaluar objetivamente el desempeño en escenarios reales de datos incompletos.

En aplicaciones hidrológicas, la evaluación del desempeño no debe limitarse a métricas generales como RMSE o MAE. El coeficiente de Nash–Sutcliffe (NSE) es

ampliamente utilizado para evaluar la calidad del ajuste entre valores observados y simulados en modelación hidrológica [10], proporcionando un criterio adicional de validación.

Además, la adopción de una metodología estructurada como CRISP-ML(Q) permite establecer puntos de control de calidad (Quality Gates) durante el ciclo de vida del modelo, reduciendo riesgos asociados a deuda técnica en sistemas de aprendizaje automático [11].

En este contexto, el presente proyecto busca integrar fundamentos estadísticos, técnicas modernas de Inteligencia Artificial y un marco metodológico estructurado para reconstruir una base de datos hidrometeorológica oficial con criterios de consistencia, validación y trazabilidad.

II. OBJETIVOS

A. Objetivo General

Reconstruir una base de datos hidrometeorológica a partir de datos oficiales proporcionados por la CONAGUA mediante técnicas de Inteligencia Artificial, imputando valores faltantes de manera consistente y preservando las propiedades estadísticas y temporales de los datos.

B. Objetivos Específicos

- Analizar la calidad y estructura estadística del conjunto de datos hidrometeorológicos.
- Identificar la distribución y patrones de valores faltantes.
- Implementar modelos clásicos y de aprendizaje profundo para la imputación.
- Evaluar el desempeño mediante métricas cuantitativas (RMSE, MAE, R^2) y métricas hidrológicas (NSE).
- Desarrollar un pipeline reproducible alineado con la metodología CRISP-ML(Q).
- Generar una base de datos reconstruida con metadatos de trazabilidad.

III. ALCANCE, SUPUESTOS Y LIMITACIONES

A. Alcance

El proyecto contempla la reconstrucción de registros hidrometeorológicos históricos con frecuencia diaria, mediante técnicas de Inteligencia Artificial y modelos estadísticos comparativos.

- El sistema permitirá:
- Procesar y limpiar datos oficiales.
- Ejecutar modelos de imputación.
- Validar estadísticamente los resultados.
- Exportar la base de datos reconstruida para uso académico.

B. Supuestos

- Los datos oficiales representan mediciones reales confiables.
- Las series presentan estructura temporal consistente.
- Los valores faltantes no son completamente aleatorios.
- Los recursos computacionales disponibles permiten el entrenamiento de los modelos seleccionados.

C. Limitaciones

- La calidad de las imputaciones depende de la calidad del preprocesamiento.
- Existen limitaciones de hardware para modelos complejos.
- El sistema no corrige errores sistemáticos de medición.
- No se contempla despliegue en producción industrial.

IV. CRITERIOS DE ÉXITO

El proyecto será considerado exitoso si:

- Las imputaciones preservan la distribución estadística original.
- Se observa mejora cuantificable frente a métodos tradicionales.
- El pipeline es reproducible.
- El sistema permite carga, imputación y exportación sin errores.
- Se cuenta con validación estadística formal documentada.

CAPÍTULO II MARCO TEÓRICO

A. Series Temporales Hidrometeorológicas

Una serie temporal se define como una sucesión ordenada de observaciones $\{X_t\}_{t=1}^T$, donde cada valor puede depender de observaciones anteriores [4]. En el contexto hidrometeorológico, X_t representa variables ambientales medidas a intervalos regulares, tales como precipitación, temperatura, evaporación, humedad relativa y niveles freáticos.

Las series hidrometeorológicas presentan características particulares:

- Dependencia temporal significativa.
- Estacionalidad anual marcada.
- Tendencias de largo plazo.
- Variabilidad interanual.
- Influencias regionales y topográficas.

Hyndman y Athanasopoulos destacan que el modelado adecuado de series temporales requiere preservar explícitamente los componentes estructurales de tendencia y estacionalidad para garantizar coherencia estadística y capacidad predictiva [4].

Además, señalan que: “A time series is said to have a seasonal pattern when fluctuations are regularly repeated over fixed periods” [4, p. 9].

En sistemas hidrológicos, la interacción entre procesos atmosféricos (precipitación, radiación solar, temperatura) y procesos terrestres (infiltración, escorrentía, almacenamiento subterráneo) genera comportamientos inherentemente no lineales [12], lo que limita la efectividad de modelos lineales tradicionales cuando se aplican a series ambientales complejas.

Esta no linealidad estructural implica que los supuestos clásicos de independencia condicional y linealidad pueden resultar insuficientes para capturar dinámicas hidrometeorológicas reales.

En escenarios multivariantes, si se considera:

$$X_t = (x_{1t}, x_{2t}, \dots, x_{nt})$$

las dependencias cruzadas entre variables deben modelarse explícitamente, ya que la correlación entre variables como precipitación y temperatura puede afectar significativamente los patrones observados [1].

B. Desafíos Específicos de Datos Hidrometeorológicos

Las bases hidrometeorológicas históricas presentan desafíos particulares:

1. Altos porcentajes de datos faltantes en registros prolongados [2].
2. Presencia frecuente de eventos extremos.
3. No linealidad estructural.
4. Heterogeneidad espacial.
5. Dependencias multivariantes complejas.

Branisavljević et al. documentan que la pérdida de datos puede comprometer análisis hidrológicos si no se implementan mecanismos formales de validación y control de calidad [2, p. 6]. En particular, la ausencia de mecanismos de trazabilidad puede generar incertidumbre en estudios de modelación hidrológica y evaluación climática.

La estacionalidad pronunciada implica que una imputación incorrecta puede alterar patrones anuales completos, afectando análisis climáticos y estimaciones de disponibilidad hídrica. Hyndman y Athanasopoulos advierten que la descomposición incorrecta de componentes estructurales puede inducir errores sistemáticos en predicción [4].

C. Fundamentos Estadísticos de Series Temporales

1) Estacionariedad

Una serie es débilmente estacionaria si:

$$\begin{aligned}E[X_t] &= \mu \\ \text{Var}(X_t) &= \sigma^2 \\ \text{Cov}(X_t, X_{t+h}) &= \gamma(h)\end{aligned}$$

La prueba KPSS fue propuesta por Kwiatkowski et al., quienes señalan que su procedimiento “tests the null hypothesis that an observable time series is stationary around a deterministic trend” [12, p. 160].

En datos hidrometeorológicos, la no estacionariedad es frecuente debido a estacionalidad anual y tendencias asociadas a variabilidad climática de largo plazo.

2) Modelo ARIMA y SARIMA

Un modelo ARIMA(p,d,q) se expresa como:

$$\phi(B)(1-B)^d X_t = \theta(B)\varepsilon_t$$

Box y Jenkins desarrollaron este enfoque bajo el supuesto de linealidad y dependencia autoregresiva [7].

El modelo SARIMA incorpora estacionalidad:

$$\Phi(B^s)\phi(B)(1-B)^d(1-B^s)^D X_t = \Theta(B^s)\theta(B)\varepsilon_t$$

Estos modelos requieren diferenciación para lograr estacionariedad y suponen estructura lineal en la dinámica temporal [7].

3) Modelos ETS

Los modelos ETS (Error, Trend, Seasonality) modelan explícitamente componentes estructurales aditivos o multiplicativos. Hyndman y Athanasopoulos explican que estos modelos permiten representar sistemas con tendencia y estacionalidad explícita dentro de un marco probabilístico [4].

No obstante, pueden presentar limitaciones ante cambios abruptos de régimen o no linealidades complejas.

D. Datos Faltantes: Marco Teórico

Little y Rubin [6] clasifican los mecanismos de datos faltantes en:

- MCAR
- MAR
- MNAR

Rubin establece: “Missing data mechanisms can be classified as missing completely at random (MCAR), missing at random (MAR), or not missing at random (NMAR)” [5, p. 586].

En registros hidrometeorológicos, los valores faltantes suelen asociarse a eventos extremos o fallas técnicas, aproximándose al mecanismo MNAR, lo que complica la inferencia estadística.

El tratamiento inadecuado puede generar:

- Sesgo en medias y varianzas.
- Alteración de autocorrelaciones.
- Degradación del desempeño predictivo.

Little y Rubin destacan que la ignorancia del mecanismo de faltante puede conducir a inferencias inconsistentes [6].

E. Métodos Tradicionales de Imputación

1) Interpolación Lineal

$$\hat{x}_t = x_{t-1} + \frac{x_{t+1} - x_{t-1}}{2}$$

Es eficiente, pero suaviza la señal y no preserva estructuras no lineales complejas [7].

2) Regresión Múltiple

$$\hat{x}_t = \beta_0 + \sum_{i=1}^k \beta_i z_{it}$$

Asume linealidad y normalidad de errores.

3) K-Nearest Neighbors (KNN)

Imputa valores utilizando observaciones similares en el espacio de características.

4) Expectation-Maximization (EM)

EM maximiza verosimilitud bajo supuestos de normalidad [6]. Aunque estadísticamente sólido, su desempeño se degrada ante relaciones altamente no lineales.

5) Multiple Imputation

Genera múltiples datasets imputados combinando resultados estadísticos [6]. Es robusto, pero computacionalmente costoso.

F. Limitaciones Estructurales de Modelos Lineales

Los modelos lineales asumen:

$$X_t = \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t$$

Sin embargo, en procesos hidrometeorológicos, la interacción entre variables atmosféricas introduce no linealidades estructurales que no pueden capturarse adecuadamente mediante modelos puramente lineales [12].

Limitaciones:

- No capturan cambios de régimen.
- Suavizan extremos.
- Modelan débilmente dependencias multivariantes.

G. Técnicas de Inteligencia Artificial

1) LSTM

Las LSTM introducidas por Hochreiter y Schmidhuber [13] modelan dependencias largas mediante compuertas:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$$

$$C_t = f_t C_{t-1} + i_t \tilde{C}_t$$

Hochreiter y Schmidhuber introdujeron las LSTM para resolver el problema del gradiente desvanecido en redes recurrentes profundas [13]. Ellos afirman que las LSTM permiten “learning to bridge minimal time lags in excess of 1000 discrete time steps” [13, p. 1736].

2) Autoencoders

Minimizan:

$$L = (x - \hat{x})^T (x - \hat{x})$$

Hinton y Salakhutdinov demostraron que las redes autoencoder profundas pueden aprender representaciones latentes eficientes para datos de alta dimensionalidad [14].

3) GAN y BRITS

Las GAN optimizan:

$$\min_G \max_D V(D, G)$$

Este esquema minimax fue introducido por Goodfellow et al., quienes establecen que el generador y el discriminador compiten en un juego adversarial donde uno intenta producir muestras indistinguibles de los datos reales mientras el otro intenta diferenciarlas [15].

En el contexto de imputación de series temporales multivariantes, Luo et al. demostraron que el aprendizaje de la distribución conjunta mediante GAN permite mejorar métricas como RMSE y MAE frente a métodos tradicionales [9].

BRITS incorpora información pasada y futura en la imputación [8], integrando el proceso de estimación de valores faltantes dentro del propio modelo recurrente bidireccional.

4) Modelos de Difusión

Simulan un proceso de ruido progresivo y su reversión, permitiendo reconstrucción robusta bajo altos niveles de datos faltantes [16].

Tashiro et al. proponen CSDI (Conditional Score-based Diffusion Models for Imputation), donde la imputación se formula como un proceso probabilístico de reversión de ruido condicionado a observaciones parciales [16].

H. Comparación Tradicional vs Deep Learning

Característica	Métodos Tradicionales	Deep Learning
Linealidad	Sí	No
Estacionalidad	Limitada	Alta
Multivariante	Débil	Fuerte
Preservación de extremos	Baja	Media-Alta
Supuestos estadísticos	Fuertes	Flexibles

La diferencia estructural entre ambos enfoques radica en la capacidad de los modelos profundos para aproximar funciones altamente no lineales sin imponer supuestos estrictos de distribución, a diferencia de los modelos clásicos que requieren linealidad y estacionariedad [7], [13].

I. Métricas de Evaluación

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

$$NSE = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

El NSE es ampliamente utilizado en hidrología [10] como medida de eficiencia predictiva entre valores observados y simulados.

Legates y McCabe demostraron que el NSE es particularmente útil en evaluación hidrológica cuando se desea medir capacidad explicativa relativa frente a la media observada [19].

J. Metodologías de Ciencia de Datos

CRISP-DM define un proceso iterativo de minería de datos estructurado en fases de comprensión del negocio, comprensión de los datos, preparación, modelado, evaluación y despliegue [17].

CRISP-ML(Q) incorpora control de calidad y gestión de riesgos específicos de modelos de aprendizaje automático, incluyendo Quality Gates y monitoreo continuo [11].

K. Arquitectura de Pipelines

Un pipeline organiza el procesamiento en etapas modulares:

1. Ingesta.
2. Limpieza.
3. Modelado.
4. Validación.
5. Persistencia.

Kleppmann destaca la importancia de sistemas reproducibles y auditables en arquitecturas de datos modernas, señalando que la trazabilidad y versionado son esenciales en sistemas intensivos en datos [18].

Conclusión del Marco Teórico

El análisis teórico desarrollado establece los fundamentos estadísticos y computacionales necesarios para abordar la reconstrucción de series hidrometeorológicas con datos faltantes.

Se evidencia que, si bien los métodos tradicionales ofrecen simplicidad y eficiencia, presentan limitaciones estructurales ante no linealidades y dependencias multivariantes complejas [7], [12].

En contraste, los modelos de aprendizaje profundo ofrecen mayor capacidad de representación y flexibilidad funcional [13], [15], justificando su aplicación en el presente proyecto bajo un marco metodológico estructurado [11].

CAPÍTULO III METODOLOGÍA DE LA INVESTIGACIÓN

A. Enfoque metodológico de la investigación

La presente investigación adopta un enfoque **cuantitativo y aplicado**, sustentado en el análisis estadístico y computacional de series temporales hidrometeorológicas y en la implementación de técnicas de aprendizaje automático para la reconstrucción de datos incompletos. El enfoque cuantitativo se justifica por la necesidad de evaluar la calidad de la reconstrucción mediante **métricas formales de error**, pruebas estadísticas y análisis comparativos reproducibles. El carácter aplicado se fundamenta en que el proyecto busca resolver un problema operativo y recurrente en bases hidrometeorológicas: **valores faltantes y discontinuidades**, que afectan análisis hidrológicos y climáticos y reducen la confiabilidad del dato para investigación [2].

En sistemas hidrometeorológicos, el aseguramiento de calidad no se limita a “rellenar” valores faltantes; requiere trazabilidad. En particular, se retoma el principio de que cada valor validado o ajustado debe acompañarse de metadatos de calidad. Branisavljević et al. establecen que:

“Every validated and sometimes improved data value is accompanied with a meta-data that holds its validation grade as a quality indicator for further use.” [2]

Este criterio orienta la metodología del proyecto: la reconstrucción debe producir una base de datos **útil, auditada y documentada**.

B. Metodología seleccionada: CRISP-ML(Q)


Para el desarrollo del proyecto se adopta la metodología CRISP-ML(Q) (Cross Industry Standard Process for Machine Learning with Quality Assurance), propuesta como una evolución de CRISP-DM para proyectos de aprendizaje automático con aseguramiento explícito de calidad y control de riesgos [11]. CRISP-DM define un proceso iterativo para

proyectos de minería de datos, pero no explicita mecanismos formales para control de calidad de modelos, gobernanza ni monitoreo posterior [17]. En cambio, CRISP-ML(Q) introduce:

1. **Quality Gates** (puntos formales de control) para validar entradas/salidas en cada fase.
2. Gestión de riesgos y trazabilidad durante el ciclo de vida.
3. Consideraciones de operación/monitoreo para degradación del modelo.

Estas extensiones son críticas en sistemas de ML, ya que la deuda técnica puede acumularse rápidamente si no se establecen controles de calidad y mantenimiento. Sculley et al. describen este problema como **deuda técnica oculta** en sistemas de ML, motivando la necesidad de procesos rigurosos y monitoreo [20]. Por tanto, CRISP-ML(Q) es metodológicamente apropiada para una reconstrucción hidrometeorológica, donde se requiere consistencia temporal, preservación de estacionalidad y control de sesgos.

Figura 3.1. Ciclo de vida del proyecto basado en CRISP-ML(Q) para datos hidrometeorológicos.



C. Fases del proyecto bajo CRISP-ML(Q)

1) Comprensión del problema

Se define el problema como un proceso de imputación y reconstrucción de series temporales hidrometeorológicas oficiales con valores faltantes y discontinuidades. El objetivo metodológico consiste en generar una base reconstruida que sea:

- **Consistente estadísticamente** (sin sesgos significativos).
- **Coherente temporalmente** (preservación de tendencia/estacionalidad/autocorrelación).
- **Plausible físicamente** (valores compatibles con rangos hidrometeorológicos).
- **Trazable** (registro del método/modelo utilizado y su calidad).

La preservación de patrones estacionales es particularmente relevante en hidrometeorología; técnicas de descomposición estacional y análisis de estructura ayudan a comprender y preservar dichos componentes [4], [7], [1].

Como criterios cuantitativos base, se adopta un conjunto de métricas de error para comparar modelos durante la fase de evaluación:

$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$; $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$; $MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Estas métricas permiten comparar desempeño de imputación en forma objetiva, considerando diferentes penalizaciones (p. ej., RMSE penaliza más los errores grandes).

2) Comprensión de los datos

Los datos corresponden a series históricas diarias de estaciones hidrometeorológicas. En esta fase se realiza un **Análisis Exploratorio de Datos (EDA)** para caracterizar:

- Cobertura temporal de cada estación/variable.

- Distribución y patrón de valores faltantes (por variable, por estación y por periodo).
- Detección de valores atípicos (outliers) y posibles inconsistencias.
- Estructura temporal: tendencia, estacionalidad y autocorrelación.

Dado que la selección de modelos depende de la estructura temporal, se evalúa la **estacionariedad** mediante la prueba **KPSS** (Kwiatkowski-Phillips-Schmidt-Shin), ampliamente utilizada para contrastar estacionariedad frente a alternativas con raíz unitaria [12]. La presencia de no estacionariedad orienta el uso de enfoques estacionales (p. ej., SARIMA/TBATS) o modelos flexibles (p. ej., Prophet o deep learning) [7], [21], [22].

3) Preparación de los datos

La preparación de datos se implementa como un pipeline reproducible que integra:

1. **Limpieza:** manejo de duplicados, formatos, rangos válidos, consistencia de unidades.
2. **Normalización/estandarización:** requerida principalmente para modelos de redes neuronales.
3. **Ingeniería de características temporales**, incluyendo:
 - a. rezagos (lags)
 - b. medias móviles/ventanas
 - c. codificación de estacionalidad (p. ej., mes/día del año)
4. **Partición temporal** en entrenamiento/validación/prueba, respetando el orden cronológico para evitar fuga de información (data leakage).


La preservación de trazabilidad exige que cada transformación sea registrable y reproducible. Este enfoque es consistente con principios de ingeniería de datos y sistemas reproducibles para análisis temporal [18].

[Pipeline de Reconstrucción Hidrometeorológica - CRISP-ML]

Figura 3.2. Pipeline local de procesamiento y aseguramiento de calidad de modelos.

Sistema Local de Reconstrucción de Base de Datos Hidrometeorológica - CRISP-ML(Q)

Pipeline local de procesamiento y aseguramiento de calidad de modelos



4) Modelado

En esta fase se implementan y comparan familias de modelos con diferentes supuestos y capacidades, con el fin de obtener un baseline robusto y modelos avanzados para imputación. Se contemplan:

a) Modelos estadísticos y de forecasting (baselines)

Se consideran enfoques clásicos y estacionales recomendados para series temporales:

- Modelos estacionales y de suavizamiento/forecasting (marco general) [[4].
- Modelos con estacionalidad compleja (TBATS) para patrones múltiples o no triviales [21].
- Enfoques tipo Prophet para componentes de tendencia y estacionalidad con flexibilidad práctica [22].

Estos modelos permiten establecer un baseline razonable y evaluar si la complejidad adicional de modelos de deep learning está justificada.

b) Aprendizaje automático (ML)

Se incorporan modelos de ML como baseline no lineal, destacando XGBoost por su eficiencia, escalabilidad y desempeño competitivo en múltiples dominios [23]. En series temporales, su uso requiere ingeniería de características (lags, calendarios, ventanas), lo que se integra en la etapa de preparación de datos.

c) Aprendizaje profundo (DL) para imputación

Se incorporan modelos específicos para imputación temporal/multivariante:

- **BRITS** (imputación recurrente bidireccional):

“Our proposed method directly learns the missing values in a bidirectional recurrent dynamical system, without any specific assumption.” [8]

Esta propiedad es particularmente útil cuando no se desea imponer supuestos rígidos sobre la distribución del faltante.

- **GAN para imputación multivariante:**

“we propose to learn the overall distribution of a multivariate time series dataset with GAN, which is further used to generate the missing values...” [9]

Esto respalda el enfoque de preservar distribución conjunta y coherencia estadística.

- **SAITS** (auto-atención para imputación): diseñado para capturar dependencias temporales con atención, útil en escenarios con patrones complejos [24].
- **CSDI** (difusión condicional probabilística): orientado a imputación probabilística y robusta ante altos niveles de faltantes [4], [7], [1].

La inclusión de modelos avanzados se justifica por la naturaleza multivariante y no lineal de datos hidrometeorológicos, donde la preservación de estacionalidad y extremos es un requisito clave [5]–[7].

5) Evaluación y Quality Gate

CRISP-ML(Q) incorpora una evaluación estructurada mediante **Quality Gates** [11]. En este proyecto, el Quality Gate se define como un conjunto de criterios mínimos que deben cumplirse antes de aceptar un modelo y exportar la base reconstruida. La evaluación integra:

a) Métricas cuantitativas (error)

Se calculan RMSE, MAE y MAPE para comparar desempeño. Además, puede incluirse R^2 como indicador complementario de ajuste cuando corresponda.

b) Preservación de estructura temporal

Se verifica que el modelo preserve:

- estacionalidad (comparación de componentes estacionales o patrones por periodo) [4], [7], [1]
- autocorrelación (comparación ACF/PACF pre- y post-imputación)
- estabilidad estadística (comparación de distribución, media/varianza por periodo)

c) Preservación de eventos extremos

La hidrometeorología depende fuertemente de extremos (lluvias intensas, máximos/mínimos). Se evalúa que el modelo no “suavice” artificialmente extremos ni cree extremos físicamente inverosímiles.

d) Trazabilidad y reproducibilidad

Se verifica que el pipeline registre configuraciones del modelo, versión de datos y parámetros de ejecución, para mitigar riesgos de mantenimiento y deuda técnica [20].

Solo los modelos que cumplen los criterios anteriores superan el Quality Gate y avanzan a despliegue.

6) Despliegue y arquitectura


El despliegue consiste en generar la base reconstruida en formatos estructurados y reproducibles (p. ej., CSV/Parquet), junto con metadatos mínimos:

- método/modelo usado por variable/segmento
- fecha de reconstrucción
- versión de pipeline/modelo
- indicadores de calidad (p. ej., métricas globales por estación/variable)

La arquitectura se organiza como pipeline secuencial modular (ingesta → preparación → modelado → evaluación → exportación). Esta organización favorece trazabilidad y mantenibilidad, principios necesarios para sistemas de datos reproducibles [18] y para evitar deuda técnica en ML [20]

Figura 3.3. Diseño arquitectónico conceptual y lógico del sistema de reconstrucción.

Arquitectura de Componentes – Reconstrucción BD Hidrometeorológica (CRISP-ML)



7) Monitoreo y mantenimiento

Se establece monitoreo para detectar degradación del proceso de imputación y cambios en la distribución de datos. En sistemas de ML, el desempeño puede deteriorarse cuando cambia la distribución de entrada:

$$P_{\text{train}}(X) \neq P_{\text{future}}(X)$$

CRISP-ML(Q) enfatiza el monitoreo continuo y re-evaluación periódica [11]. Además, la literatura de sistemas de ML advierte que cambios pequeños pueden introducir efectos acumulativos y deuda técnica, por lo que se requieren prácticas de mantenimiento y control [20].

En el contexto hidrometeorológico, la distribución puede variar por cambios climáticos o cambios instrumentales. Por ello, se definen criterios para reentrenamiento o recalibración cuando se detecten desviaciones persistentes en estadísticos descriptivos o desempeño.

D. Síntesis metodológica y alineación con el proyecto

La metodología propuesta integra:

1. **Fundamento estadístico** (estructura temporal, estacionariedad y validación).
2. **Comparación multi-enfoque** (estadísticos, ML y DL).
3. **Aseguramiento de calidad** mediante CRISP-ML(Q) y Quality Gates [11].
4. **Mitigación de deuda técnica** y soporte a mantenimiento [20].
5. **Enfoque moderno de imputación** (BRITS/GAN/atención/difusión) para series complejas [8], [9], [16], [24]

Con ello, el proyecto produce una base hidrometeorológica reconstruida con criterios de consistencia, plausibilidad y trazabilidad alineados a exigencias académicas y buenas prácticas de sistemas de ML.

CAPÍTULO IV DISEÑO Y ARQUITECTURA DEL SISTEMA

A. Requerimientos del sistema

La especificación de requerimientos constituye una etapa esencial en el desarrollo de sistemas de software, ya que permite delimitar el comportamiento esperado del sistema y asegurar su alineación con los objetivos del proyecto y su alcance definido [25], [26]. En sistemas basados en aprendizaje automático, esta etapa adquiere mayor relevancia debido a la necesidad de garantizar reproducibilidad experimental, trazabilidad del dato y control de calidad del modelo a lo largo de su ciclo de vida [20], [31].

En esta sección se describen las capacidades y restricciones del sistema de reconstrucción de la base de datos hidrometeorológica a partir de datos oficiales proporcionados por la CONAGUA, asegurando coherencia con los principios de arquitectura modular y procesamiento orientado a datos [18].

1) Requerimientos funcionales

Los requerimientos funcionales describen las funciones específicas que el sistema debe proporcionar para permitir la reconstrucción de la base de datos mediante técnicas de imputación generativa [9], [16], dentro de un pipeline estructurado y validable.

ID	Requerimiento Funcional	Descripción
RF-01	Carga de datos	El sistema debe permitir la carga de datasets hidrometeorológicos de la CONAGUA en formatos estructurados [18]. Esta carga deberá incluir validaciones básicas de esquema, tipos de datos y consistencia temporal para evitar propagación de errores en etapas posteriores.
RF-02	Organización de datos	El sistema debe organizar los datos por estación, variable y periodo temporal, garantizando su correcta indexación mediante claves compuestas y orden cronológico consistente [18], [37]
RF-03	Identificación de valores faltantes	El sistema debe identificar valores nulos, ausentes o inconsistentes en las series temporales [5], [6], conservando banderas de calidad que permitan auditoría posterior del proceso de reconstrucción.
RF-04	Preprocesamiento de datos	El sistema debe realizar limpieza, normalización y escalamiento de los datos antes del modelado [3], [36], incluyendo alineación temporal, generación de variables derivadas (lags, variables estacionales) y segmentación lógica para entrenamiento y validación.
RF-05	Imputación generativa	El sistema debe imputar valores faltantes mediante modelos de Inteligencia Artificial (LSTM, GAN, etc.) [13], [15], permitiendo comparación entre enfoques estadísticos clásicos y modelos profundos especializados en series temporales multivariantes [8], [9], [16], [24].
RF-06	Validación estadística	El sistema debe evaluar la calidad de las imputaciones mediante métricas como RMSE y MAE, complementadas con verificación de

		preservación de estacionalidad, autocorrelación y comportamiento de extremos hidrometeorológicos [10], [19].
RF-07	Exportación de resultados	El sistema debe permitir exportar la base de datos reconstruida en formatos adecuados para análisis posterior [18], incluyendo metadatos que indiquen qué valores fueron imputados y bajo qué modelo.
RF-08	Reproducibilidad	El sistema debe permitir ejecutar el pipeline completo bajo configuraciones reproducibles [11], [30], registrando semillas aleatorias, versiones de modelo y parámetros utilizados.

4.1.2 Requerimientos no funcionales

Estos definen atributos de calidad y restricciones fundamentales para el desempeño en un entorno de investigación [20], [31].

- **NFR-01 Rendimiento:** El sistema debe ejecutarse en tiempos razonables considerando el volumen de datos y los recursos computacionales disponibles [18].
- **NFR-02 Reproducibilidad:** Garantizar resultados consistentes cuando se ejecuta bajo las mismas condiciones y semillas aleatorias [30].
- **NFR-03 Usabilidad:** El sistema debe ser fácil de utilizar por investigadores del Laboratorio de Geomática, sin requerir conocimientos avanzados de programación [31].
- **NFR-04 Compatibilidad:** Compatibilidad con entornos basados en Python 3.x y librerías de ciencia de datos estándar [33], [34], [35]
- **NFR-05 Mantenibilidad:** El código debe ser modular, documentado y fácil de extender para futuras investigaciones [25].
- **NFR-06 Escalabilidad:** Permitir el procesamiento de datos de múltiples estaciones y periodos sin degradar el funcionamiento general [27].
- **NFR-07 Trazabilidad:** Cada valor imputado deberá poder asociarse al modelo y ejecución que lo generó, asegurando auditabilidad completa del proceso [18], [32].

2) Decisiones arquitectónicas y Estilo

El presente apartado describe las decisiones adoptadas para el diseño del sistema de reconstrucción mediante técnicas de Inteligencia Artificial [36], [23]. El sistema adopta un estilo arquitectónico basado en pipeline de procesamiento de datos, en el cual los datos hidrometeorológicos fluyen de manera secuencial a través de módulos especializados [27].

Este estilo permite una clara separación de responsabilidades (Separation of Concerns), facilita la validación por etapas y favorece la reproducibilidad del proceso de imputación [26], [28]. El modularidad reduce la acumulación de deuda técnica en sistemas de aprendizaje automático y permite sustituir modelos sin afectar el resto de la arquitectura [20].

Para la implementación, se emplean los siguientes patrones:

- **Arquitectura modular:** Los componentes se desarrollan y mantienen de manera independiente [25]
- **Procesamiento por etapas:** Permite validar resultados intermedios antes de la imputación final [11].
- **Diseño orientado a datos:** Centrado en la transformación y análisis de datasets hidrometeorológicos complejos [18].

Estas decisiones responden a la necesidad de garantizar la aplicación de los requerimientos y facilitar la experimentación con diferentes modelos de Inteligencia Artificial, asegurando la escalabilidad y mantenibilidad del software [20], [31].

3) Arquitectura Conceptual

La arquitectura conceptual presenta una vista de alto nivel del sistema y del flujo general de datos, identificando los módulos principales sin considerar detalles de implementación tecnológica [26].




Figura 4.1. Arquitectura conceptual del sistema de reconstrucción hidrometeorológica.

Como se observa en la Figura 4.1, los componentes conceptuales identificados cubren explícitamente las etapas de: Ingesta de datos (CONAGUA), Módulo de procesamiento (limpieza y normalización), Módulo de Machine Learning (imputación con modelos generativos) y Módulo de salida (dataset reconstruido y validado) [9], [3], [9], [16].

El flujo secuencial garantiza trazabilidad desde el dato crudo hasta la versión reconstruida, alineándose con los principios de ingeniería de datos orientados a control estructural del pipeline [18].

4) Arquitectura Lógica

La arquitectura lógica describe la estructura interna del sistema desde el punto de vista del software, detallando los módulos, sus interfaces y las interacciones entre componentes [29].

Figura 4.2. Diagrama UML lógico de componentes del sistema.




Figura 4.2. Diagrama UML lógico de componentes del sistema.

De acuerdo con la Figura 4.2, los módulos se comunican mediante interfaces de datos estandarizadas (DataFrames), garantizando un acoplamiento bajo. El flujo de información se realiza de manera secuencial, donde cada módulo consume la salida generada por el módulo anterior, facilitando la trazabilidad del dato desde la ingesta hidrometeorológica hasta la generación de resultados validados [33], [18].

1) FuenteDatosCONAGUA (Fuente de datos)

Propósito

- Representa el **origen oficial** de la información hidrometeorológica (CONAGUA / SMN).
- Provee los archivos o registros “crudos” (raw) del **registro diario histórico** y sus atributos asociados.

Qué entrega

- Datos tal como vienen publicados/entregados: archivos planos, tablas, CSV/Excel, etc.
- En esta etapa todavía pueden existir: faltantes, formatos inconsistentes, duplicados, fechas mal formateadas, valores fuera de rango.

Interfaz asociada

- Produce datos hacia IngestaDatos mediante la interfaz **IDataIngested** (en el diagrama aparece como el contrato de intercambio).

2) IngestaDatos

Propósito

- Ejecuta la carga inicial de los datos y una validación mínima de estructura.
- Asegura que el dataset sea “legible” por el resto del pipeline.

Funciones típicas

- Lectura de archivos (CSV/Excel/DB export).
- Normalización de nombres de columnas y tipos básicos.
- Validaciones de forma: columnas obligatorias presentes, encoding, separadores, formato de fecha parseable.
- Asignación de identificadores (por ejemplo: estación, variable, periodo).
- Registro de bitácora (cuántos registros entraron, de qué rango temporal).

Entrada / Salida

- **Entrada:** datos desde FuenteDatosCONAGUA.
- **Salida:** un DataFrame o estructura estándar con esquema mínimo consistente.
- Interfaz de salida: **IDataIngested**.

3) LimpiezaValidacionDatos

Propósito

- Hace la **limpieza de calidad** y validaciones de consistencia antes de preparar el modelado.
- Aquí se “corrige lo corregible” y se **marca** lo dudoso (sin inventar valores todavía).

Funciones típicas

- Eliminación de duplicados (por clave: estación–fecha–variable).
- Conversión robusta de tipos (fechas, numéricos).
- Manejo de valores imposibles o sospechosos:
 - rangos físicos (p. ej., precipitación negativa),
 - temperaturas fuera de rango razonable,
 - saltos imposibles por límites instrumentales.
- Reglas de consistencia temporal:
 - fechas fuera del periodo,
 - registros no ordenados,
 - huecos identificados.
- Generación de “flags” de calidad:
 - is_missing, is_outlier, is_invalid, source_quality_flag, etc.

Entrada / Salida

- **Entrada:** IDataIngested.
- **Salida:** datos “limpios” + banderas de calidad + reporte de limpieza.
- Interfaz de salida: **IDataCleaned**.

4) Preprocesamiento Datos

Propósito

- Prepara los datos específicamente para **imputación/reconstrucción** (modelos estadísticos o IA).
- Este módulo crea la “vista de modelado” con estructura temporal adecuada.

Funciones típicas

- Alineación a frecuencia diaria (si hay huecos, se generan timestamps faltantes explícitos).
- Transformaciones para estabilizar comportamiento:
 - escalamiento/normalización,
 - transformaciones (log/Box-Cox si aplica),
 - manejo de estacionalidad (features de día del año/mes).
- Construcción de características (feature engineering):
 - rezagos (lags), ventanas móviles, acumulados,
 - variables calendáricas (día, mes, DOY),
 - indicadores de estacionalidad,
 - (si aplica) combinación multi-variable (p. ej. usar temperatura/humedad para apoyar imputación).
- Segmentación lógica para modelado:
 - separar tramos con alta continuidad,
 - preparar máscaras de faltantes,
 - preparar conjuntos train/val/test cuando aplica (sin filtrar “futuro” al “pasado”).

Entrada / Salida

- **Entrada:** IDataCleaned.
- **Salida:** dataset listo para reconstrucción (matrices, secuencias, máscaras, features).
- Interfaz de salida: **IDataPreprocessed**.

5) Reconstrucción IA

Propósito

- Es el **núcleo inteligente** del sistema: reconstruye valores faltantes o segmentos incompletos usando técnicas de IA/ML.
- Debe respetar la estructura temporal y evitar introducir sesgos evidentes.

Qué hace

- Selecciona/entrena/aplica el modelo de imputación:
 - Modelos clásicos (ej. regresión, kNN, árboles/boosting),
 - Series de tiempo (ARIMA/ETS según aplique),
 - Deep Learning para secuencias (LSTM/GRU/TCN/Transformers, si lo estás usando en tu tesis).
- Estrategias de reconstrucción:
 - imputación puntual para huecos cortos,
 - reconstrucción por tramos (bloques largos),
 - modelos por estación/variable o globales (dependiendo diseño).
- Control de coherencia:
 - límites físicos post-proceso,
 - suavizado opcional si el modelo genera ruido,
 - preservación de estacionalidad.

Salida esperada

- Serie reconstruida + métricas del modelo (por estación/variable) + flags indicando qué fue imputado.

Entrada / Salida

- **Entrada:** IDataPreprocessed.
- **Salida:** series reconstruidas.
- Interfaz de salida: **IReconstructedSeries**.

6) ValidacionEstadistica

Propósito

- Evalúa si la reconstrucción es **acceptable** y consistente con el comportamiento histórico.
- Este componente funciona como tu **Quality Gate** (tu “paso de control” antes de persistir resultados).

Validaciones típicas

- Métricas cuantitativas (si tienes verdad terreno parcial o validación por enmascaramiento):
 - MAE, RMSE, MAPE, R^2 , NSE/KGE (si lo incluyes),

- comparación por estaciones y por periodos (seca/lluvia).
- Pruebas estadísticas / consistencia temporal:
 - distribución antes vs después (KS, comparaciones por cuantiles),
 - autocorrelación/estructura temporal,
 - estabilidad/estacionariedad (ej. KPSS si lo integraste en tu metodología).
- Validación de extremos (muy importante en hidrometeorología):
 - no “aplanar” picos de precipitación,
 - no inventar máximos imposibles,
 - coherencia de eventos.
- Generación de dictamen:
 - “aprobado / observado / rechazado”,
 - y reporte con hallazgos.

Entrada / Salida

- **Entrada:** IReconstructedSeries.
- **Salida:** resultados validados + reporte.
- Interfaz de salida: **IValidatedResults**.

7) PersistenciaDatos

Propósito

- Almacena de forma organizada los resultados finales para uso operativo y trazabilidad.
- Es el punto donde tu pipeline deja “artefactos confiables” listos para consulta.

Qué persiste

- Serie final reconstruida (diaria) con banderas:
 - valor original vs imputado,
 - método/modelo usado,
 - versión del modelo,
 - fecha de ejecución.
- Tablas auxiliares:
 - bitácoras de limpieza,
 - reportes de validación,
 - métricas,
 - metadatos mínimos de trazabilidad (muy útil para tu tesis).

Relación con el diagrama

- Consume IValidatedResults (solo se guarda si pasa la validación o se guarda con estatus).
- Sirve como fuente para el módulo final de análisis/exportación.

8) AnalisisExportacionResultados

Propósito

- Convierte lo almacenado en **salidas útiles**: análisis, reportes y exportaciones para usuarios/consumidores.
- Este componente responde a tu idea de “Analytical & export module”.

Funciones típicas

- Consultas analíticas:
 - estadísticas descriptivas,
 - tendencias,
 - comparativas antes/después,
 - indicadores por estación/periodo.
- Exportación:
 - CSV/Excel,
 - gráficos,
 - reportes PDF/HTML (si aplica),
 - datasets listos para otros modelos.
- Productos para tesis:
 - tablas de métricas,
 - figuras de validación,
 - reporte de Quality Gate.

Relación con PersistenciaDatos

- En el diagrama se ve como un componente que **depende** de PersistenciaDatos para leer los resultados ya validados y producir salidas.

5) Arquitectura Física y Stack Tecnológico

El sistema está diseñado para su ejecución en estaciones de trabajo locales del Laboratorio de Geomática y Teledetección [31].

Hardware: Procesadores multinúcleo y aceleración GPU para el entrenamiento de redes profundas cuando sea necesario [36].

Software: El stack incluye Python 3.x y librerías como pandas y NumPy para manipulación de datos, así como TensorFlow o PyTorch para el motor de Inteligencia Artificial [33], [34], [35]. Se recomienda incorporar mecanismos de seguimiento

experimental que permitan registrar configuraciones, métricas y versiones de modelo, asegurando reproducibilidad del ciclo de vida de ML [30].

6) Modelo de Datos (Diagrama Entidad-Relación)

Para garantizar la integridad y persistencia de la información reconstruida, se ha diseñado un modelo relacional que organiza la jerarquía climática.




Figura 4.4. Diagrama Entidad-Relación de la base de datos hidrometeorológica.

Como ilustra la Figura 4.4, la entidad central EstacionClimatologica (identificada por su id_estacion PK) se vincula de manera jerárquica (1:N) con los registros Diarios, Mensuales y Anuales. Esto asegura que cada valor imputado (precipitación, temperaturas extremas, evaporación) esté correctamente georreferenciado y fechado, permitiendo una trazabilidad total de la reconstrucción [18], [32], [37].

Para fortalecer la auditabilidad del sistema, pueden incorporarse entidades adicionales de seguimiento tales como registros de ejecución del modelo, métricas obtenidas y estado de validación, alineadas con los principios de trazabilidad definidos en los requerimientos no funcionales.

7) Suposiciones y restricciones arquitectónicas

El diseño arquitectónico se basa en los siguientes supuestos: la disponibilidad de datos históricos de CONAGUA, el uso exclusivamente académico del sistema y conocimientos básicos de análisis de datos por parte del usuario.

Como restricciones, el sistema operará bajo limitaciones de hardware propias del entorno académico y se ejecutará localmente sin dependencia de infraestructura en la nube, utilizando herramientas de software de libre acceso [30], [33], [34], [35].

8) Cierre del capítulo

La integración de las vistas conceptual, lógica y de datos garantiza una solución técnica coherente con los requerimientos de investigación. Esta estructura modular basada en CRISP-ML(Q) facilita la experimentación controlada, la trazabilidad completa del dato y la reproducibilidad de los resultados hidrológicos [11], [18], [30].

5. Glosario: definiciones, siglas y abreviaturas

DAS: Documento de Arquitectura de Software. Documento que describe la estructura, componentes y decisiones arquitectónicas del sistema.

CONAGUA: Comisión Nacional del Agua. Institución encargada de la gestión y publicación de datos hidrometeorológicos oficiales en México.

Imputación: Proceso de estimación y sustitución de valores faltantes en un conjunto de datos.

Machine Learning (ML): Rama de la Inteligencia Artificial que permite a los sistemas aprender patrones a partir de datos.

Pipeline: Flujo de procesamiento que integra de manera secuencial las distintas etapas del sistema.

Product Owner (PO): Responsable de definir y priorizar los requerimientos del proyecto y validar los entregables.

Product Backlog: Listado priorizado de historias de usuario y tareas que se pretenden desarrollar durante el proyecto.

RF: Requerimiento Funcional.

NFR: Requerimiento No Funcional.

6. Conclusiones generales del documento

El presente documento define de manera formal la arquitectura de software del sistema de reconstrucción de bases de datos hidrometeorológicas, desarrollado para el Laboratorio de Geomática y Teledetección a partir de datos oficiales de la CONAGUA. A lo largo del documento se establecieron los lineamientos arquitectónicos, los componentes del sistema, las interacciones entre módulos y la infraestructura tecnológica necesaria para su correcta implementación.

La arquitectura propuesta permite abordar de manera estructurada el procesamiento de grandes volúmenes de datos hidrometeorológicos, incorporando técnicas de Inteligencia Artificial para la imputación generativa de valores faltantes, garantizando la reproducibilidad, escalabilidad y mantenibilidad del sistema. Asimismo, la definición de requisitos no funcionales, restricciones y riesgos arquitectónicos contribuye a mitigar posibles problemas técnicos y de integración durante el desarrollo.

En conjunto, este documento proporciona una base sólida para la ejecución del proyecto, alineando los objetivos técnicos, académicos y funcionales con una solución arquitectónica coherente, lo que permitirá avanzar de forma ordenada hacia las fases de implementación, validación estadística y entrega final del sistema.

Bibliografía

Referencias buenas:

- [1] G. E. P. Box, G. M. Jenkins, G. C. Reinsel y G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Wiley, 2015.
- [2] N. Branisavljević et al., “Hydro-Meteorological Data Quality Control and Validation Framework,” 2019.
- [3] A. Alotaibi et al., “Data Cleaning: A Comprehensive Survey,” *Information*, vol. 14, no. 5, 2023.
- [4] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed., 2021.
- [5] D. B. Rubin, “Inference and Missing Data,” *Biometrika*, vol. 63, no. 3, pp. 581–592, 1976.
- [6] R. J. A. Little y D. B. Rubin, *Statistical Analysis with Missing Data*, 2nd ed. Wiley, 2002.
- [7] G. E. P. Box y G. M. Jenkins, *Time Series Analysis: Forecasting and Control*, Holden-Day, 1970.
- [8] W. Cao et al., “BRITS: Bidirectional Recurrent Imputation for Time Series,” in *Advances in Neural Information Processing Systems*, 2018.
- [9] Y. Luo, Y. Cai, X. Zhang y J. Yuan, “Multivariate Time Series Imputation with Generative Adversarial Networks,” in *Advances in Neural Information Processing Systems*, 2018.
- [10] J. E. Nash y J. V. Sutcliffe, “River flow forecasting through conceptual models,” *Journal of Hydrology*, vol. 10, no. 3, pp. 282–290, 1970.
- [11] S. Studer et al., “Towards CRISP-ML(Q): A Machine Learning Process Model with Quality Assurance,” *Machine Learning and Knowledge Extraction*, vol. 3, 2021.
- [12] D. Kwiatkowski, P. C. B. Phillips, P. Schmidt y Y. Shin, “Testing the null hypothesis of stationarity against the alternative of a unit root,” *Journal of Econometrics*, vol. 54, no. 1–3, pp. 159–178, 1992.
- [13] S. Hochreiter y J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [14] G. E. Hinton y R. R. Salakhutdinov, “Reducing the Dimensionality of Data with Neural Networks,” *Science*, vol. 313, no. 5786, pp. 504–507, 2006.

- [15] I. Goodfellow et al., "Generative Adversarial Nets," in *Advances in Neural Information Processing Systems*, 2014.
- [16] Y. Tashiro, J. Song, Y. Song y S. Ermon, "CSDI: Conditional Score-based Diffusion Models for Probabilistic Time Series Imputation," in *Advances in Neural Information Processing Systems*, 2021.
- [17] CRISP-DM Consortium, *CRISP-DM 1.0: Step-by-step Data Mining Guide*, 2000.
- [18] M. Kleppmann, *Designing Data-Intensive Applications*, O'Reilly Media, 2017.
- [19] D. R. Legates y G. J. McCabe Jr., "Evaluating the use of 'goodness-of-fit' measures in hydrologic and hydroclimatic model validation," *Water Resources Research*, vol. 35, no. 1, pp. 233–241, 1999.
- [20] D. Sculley, G. Holt, D. Golovin, E. Davydov, T. Phillips, D. Ebner, V. Chaudhary y M. Young, "Hidden Technical Debt in Machine Learning Systems," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2015, pp. 2503–2511.
- [21] A. M. De Livera, R. J. Hyndman y R. D. Snyder, "Forecasting Time Series With Complex Seasonal Patterns Using Exponential Smoothing," *Journal of the American Statistical Association*, vol. 106, no. 496, pp. 1513–1527, 2011.
- [22] S. J. Taylor y B. Letham, "Forecasting at Scale," *The American Statistician*, vol. 72, no. 1, pp. 37–45, 2018.
- [23] T. Chen y C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proc. 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, 2016, pp. 785–794.
- [24] (SAITS – referencia real) X. Du, Y. Wang, J. Li y Z. Zhang, "SAITS: Self-Attention-based Imputation for Time Series," *Expert Systems with Applications*, 2023.
- [25] I. Sommerville, *Software Engineering*, 10th ed. Pearson, 2016.
- [26] L. Bass, P. Clements, and R. Kazman, *Software Architecture in Practice*, 4th ed. Addison-Wesley, 2022.
- [27] G. Hohpe and B. Woolf, *Enterprise Integration Patterns: Designing, Building, and Deploying Messaging Solutions*. Addison-Wesley, 2004.
- [28] F. Buschmann, R. Meunier, H. Rohnert, P. Sommerlad, and M. Stal, *Pattern-Oriented Software Architecture: A System of Patterns*. Wiley, 1996.

- [29] M. Shaw and D. Garlan, *Software Architecture: Perspectives on an Emerging Discipline*. Prentice Hall, 1996.
- [30] M. Zaharia et al., “Accelerating the Machine Learning Lifecycle with MLflow,” *IEEE Data Engineering Bulletin*, vol. 41, no. 4, pp. 39–45, 2018.
- [31] S. Amershi et al., “Software Engineering for Machine Learning: A Case Study,” in *Proc. IEEE/ACM International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP)*, 2019, pp. 291–300.
- [32] N. Polyzotis, S. Roy, S. E. Whang, and M. Zinkevich, “Data Management Challenges in Production Machine Learning,” in *Proc. ACM SIGMOD*, 2017, pp. 1723–1726.
- [33] W. McKinney, “Data Structures for Statistical Computing in Python,” in *Proc. 9th Python in Science Conference (SciPy)*, 2010, pp. 51–56.
- [34] M. Abadi et al., “TensorFlow: A System for Large-Scale Machine Learning,” in *Proc. 12th USENIX Symposium on Operating Systems Design and Implementation (OSDI)*, 2016, pp. 265–283.
- [35] A. Paszke et al., “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems*, 2019, pp. 8024–8035.
- [36] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [37] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Wiley, 2013.

[1] M. Meng et al., “Deep Learning Approaches for Hydrometeorological Time Series Reconstruction,” 2024.

[2] Y. Gong et al., “Advanced Generative Models for Time Series Imputation,” 2024.

- [3] "Diffusion-Based Models for Time Series Reconstruction," 2024.
- [4] "Hydro-Meteorological Data Quality Assessment Framework," 2020.
- [5] "Evaluation of Various Precipitation Products Using Ground-Based Discharge Observation," 2021.
- [6] "Reference Statistics for the Structure of Measurement Series of Groundwater Levels," 2019.
- [7] "Seasonal Trend Decomposition for Environmental Time Series," 2021.
- [8] "Hydrological Models and Distributed Hydrological Modelling," 2022.
- [9] "Cleansing a Dataset: Methodological Framework," 2020.
- [10] "KPSS Test for Stationarity in Hydrological Time Series," 2018.
- [11] "Cross-Validation Strategies for Time Series Forecasting," 2018.
- [12] "Autoencoder-Based Missing Data Imputation in Multivariate Time Series," 2018.
- [13] "GRU Networks for Multivariate Hydrological Forecasting," 2019.
- [14] "Recurrent Neural Networks for Time Series Imputation," 2017.
- [15] "BRITS: Bidirectional Recurrent Imputation for Time Series," NeurIPS, 2018.
- [16] "GAN-Based Missing Data Imputation," 2019.
- [17] "Experimental Evaluation of Deep Learning for Environmental Datasets," 2021.
- [18] "Statistical Structure of Hydrological Time Series," 2007.
- [19] "Data Quality Challenges in Environmental Monitoring Systems," 2019.
- [20] "Statistical Treatment of Missing Values in Environmental Data," 2015.
- [21] "Time Series Decomposition Methods Applied to Hydrological Data," 2021.
- [22] "Machine Learning Techniques for Environmental Forecasting," 2022.
- [23] "Deep Neural Networks for Climate Data Reconstruction," 2023.
- [24] "Multivariate Time Series Modeling for Hydro-Climatic Systems," 2020.
- [25] "Comparative Study of Imputation Methods for Environmental Data," 2019.
- [26] "Robust Missing Data Reconstruction in Hydrological Records," 2022.

- [27] "Hydrological Time Series Forecasting Using LSTM Networks," 2021.
- [28] "Deep Generative Models for Multivariate Environmental Data," 2023.
- [29] "CRISP-DM 1.0: Step-by-step Data Mining Guide," 2000.
- [30] "CRISP-ML(Q): A Process Model for Machine Learning Projects," 2020.
- [31] M. Shaw and D. Garlan, *Software Architecture: Perspectives on an Emerging Discipline*. Prentice Hall, 1996.
- [32] F. Buschmann et al., *Pattern-Oriented Software Architecture, Volume 1: A System of Patterns*. Wiley, 1996.
- [33] L. Bass, P. Clements, and R. Kazman, *Software Architecture in Practice*, 3rd ed. Addison-Wesley, 2013.
- [34] I. Sommerville, *Software Engineering*, 10th ed. Pearson, 2016.
- [35] M. Kleppmann, *Designing Data-Intensive Applications*. O'Reilly, 2017.
- [36] G. Hohpe and B. Woolf, *Enterprise Integration Patterns*. Addison-Wesley, 2003.
- [37] D. Sculley et al., "Hidden Technical Debt in Machine Learning Systems," NeurIPS, 2015.
- [38] S. Amershi et al., "Software Engineering for Machine Learning: A Case Study," ICSE, 2019.
- [39] N. Polyzotis et al., "Data Management Challenges in Production Machine Learning," SIGMOD, 2018.
- [40] M. Zaharia et al., "Accelerating the Machine Learning Lifecycle with MLflow," 2018.

Enlaces importantes hasta ahora (no parte del documento solo para guia):

Donde encontrar datasets sinaloa:

<https://data.mendeley.com/datasets/gb8jp62vm5/4>

<https://smn.conagua.gob.mx/es/climatologia/informacion-climatologica/informacion-estadistica-climatologica>

Proyectos importantes:

https://github.com/Zastha/Notebook_Prediclima?tab=readme-ov-file

https://github.com/ZurielMF/86-Y-Metereological_data

Exploratory data analysis Notebook:

https://nbviewer.org/github/Tanu-N-Prabhu/Python/blob/master/Exploratory_data_Analysis.ipynb

Data Cleaning with Python using Pandas Library:

<https://towardsdatascience.com/data-cleaning-with-python-using-pandas-library-c6f4a68ea8eb/>

Para ver notebooks de terceros:

<https://nbviewer.org/>

Enlaces importantes hasta ahora:

Donde encontrar datasets sinaloa:

<https://data.mendeley.com/datasets/qb8jp62vm5/4>

<https://smn.conagua.gob.mx/es/climatologia/informacion-climatologica/informacion-estadistica-climatologica>

Proyectos importantes:

https://github.com/Zastha/Notebook_Prediclima?tab=readme-ov-file

https://github.com/ZurielMF/86-Y-Metereological_data

Exploratory data analysis Notebook:

https://nbviewer.org/github/Tanu-N-Prabhu/Python/blob/master/Exploratory_data_Analysis.ipynb

Data Cleaning with Python using Pandas Library:

<https://towardsdatascience.com/data-cleaning-with-python-using-pandas-library-c6f4a68ea8eb/>

Para ver notebooks de terceros:

<https://nbviewer.org/>