

Estructuración Final del Dataset Organizado

Descripción general

Después del proceso de ingesta y preprocesamiento de los datos crudos provenientes de la Base de Datos Climatológica Nacional (SMN–CONAGUA), se implementó una estructura jerárquica de almacenamiento orientada a facilitar:

- La trazabilidad del dato original.
- El acceso eficiente por estación.
- El análisis temporal por año.
- El procesamiento por variable climática.
- La integración con el pipeline de modelado y reconstrucción.


La organización sigue un enfoque tipo *data engineering*, diferenciando explícitamente las capas raw e interim.

Estructura de Directorios

La estructura final del dataset organizado es la siguiente:

data/

```
|— raw/
|   |— conagua_smn/
|       |— estado=sin/
|           |— fuente=normales_climatologicas/
|               |— producto=diarios_txt/
|                   |— dia25001.txt
|                   |— dia25002.txt
|                   |— ...
|
|— interim/
    |— organized/
        |— estado=sin/
            |— estacion=25001/
                |— year=1961/
                    |— precip.csv
```



Organización Jerárquica

La estructura responde a tres niveles principales:

Nivel 1 - Estación

Cada estación meteorologica se almacena en un directorio independiente

estacion=25001/

Donde:

- 25001 corresponde a la clave oficial de estacion definida por CONAGUA
- Se mantiene el identificador original para preservar coherencia con la fuente oficial.

Nivel 2 - Año

Dentro de cada estación, los datos se organizan por año calendario

year=1961/

year=1962/

...

Esto permite:

- Acceso eficiente a periodos especificos
- Segmentacion temporal para entrenamientos y validacion de modelos

- Reduccion de carga en memoria al trabajar por particiones anuales

Nivel 3 – Varibale Climatica

Dentro de cada carpeta anual, los datos se almacenan por variable

Precip.csv / precip.parquet

Evap.csv / evap.parquet

Tmax.csv / tmax.parquet

Tmin.csv / tmin.parquet

Cada archivo contiene:

date	Fecha en formato YYYY-MM-DD
value	Valor observado de la variable

Variables Incuidas

Las variables organizadas corresponden a:

- **PRECIP** → Precipitación diaria (mm)
- **EVAP** → Evaporación diaria (mm)
- **TMAX** → Temperatura máxima diaria (°C)
- **TMIN** → Temperatura mínima diaria (°C)

Los valores faltantes originalmente etiquetados como “NULO” fueron convertidos a valores nulos estándar NaN.

Convenciones de Nomenclatura

Se adoptaron convenciones tipo key=value para carpetas, lo cual:

- Facilita escalabilidad futura (ej. agregar otros estados).
- Permite integración sencilla con sistemas tipo Hive o Spark.
- Mantiene claridad semántica.

Ejemplos:

- estado=sin
- Estacion=25001
- Year=1961

Los archivos isguen la convención:

<variable>.csv

<variable>.parquet

En minúsculas para mantener uniformidad.

Formatos de Almacenamiento

Se utilizaron dos formatos complementarios:

CSV

- Alta compatibilidad.
- Fácil inspección manual.
- Interoperabilidad con herramientas externas.

Parquet

- Formato columnar optimizado.
- Mayor eficiencia en lectura/escritura.
- Menor tamaño en disco.
- Preserva tipos de datos.
- Recomendado para modelado y procesamiento masivo.

Archivo de Índice Global

Se generó un archivo:

_index.csv

El cual contiene:

station	Clave de estación
year	Año
variable	Variable climática
Path_parquet	Ruta del archivo parquet
Path_csv	Ruta del archivo csv
rows	Número de registros
Missing_pct	Porcentaje de valores faltantes

Este índice permite:

- Auditoría de datos.
- Monitoreo de calidad.
- Evaluación de cobertura temporal.
- Trazabilidad completa del procesamiento.

Justificación Arquitectónica

La organización implementada responde a principios de:

- Modularidad.
- Separación de capas (raw vs interim).
- Escalabilidad.
- Reproducibilidad.
- Trazabilidad del dato.

Además, esta estructura facilita:

- Implementación de pipelines de imputación generativa.
- División train/validation/test por año.
- Modelado por estación o multivariado.