

Reporte de Análisis de Valores Faltantes

1. Introducción

Este reporte documenta el análisis de valores faltantes en la base de datos hidrometeorológica del estado de Sinaloa. A diferencia de análisis basados en estadísticas agregadas, este trabajo opera directamente sobre los 19,220 archivos parquet individuales que contienen los 6,392,652 registros diarios reales, lo que permite detectar patrones estacionales y rachas de días consecutivos sin dato que no serían visibles de otra forma.

El análisis cubre las variables PRECIP (precipitación), EVAP (evaporación), TMAX (temperatura máxima) y TMIN (temperatura mínima) para 168 estaciones meteorológicas del estado de Sinaloa con registros históricos diarios que abarcan desde 1941 hasta 2025.

2. Objetivos

- Mapear y cuantificar los valores nulos por estación y variable climática a nivel de registro diario.
- Generar heatmaps que visualicen la distribución espacial y temporal de los faltantes.
- Identificar patrones, tendencias y agrupaciones de valores nulos en los datos.
- Analizar rachas de días consecutivos sin dato para orientar estrategias de imputación.
- Elaborar recomendaciones para el tratamiento de valores faltantes en etapas posteriores.

3. Metodología

Se cargaron los 19,220 archivos parquet individuales desde la capa interim del proyecto y se construyó un dataframe unificado de 6,392,652 registros. A cada registro se le asignó una columna binaria `is_null` (1 = faltante, 0 = dato válido), que permitió calcular porcentajes de faltantes a nivel de día, mes y año sin pérdida de granularidad.

Se generaron siete visualizaciones: heatmap estación-variable, heatmap temporal año-variable, patrón estacional por mes, heatmap mes-variable anotado, histogramas de rachas de faltantes, clasificación de estaciones y correlación de faltantes entre variables. Las visualizaciones de patrón estacional y rachas son exclusivas del análisis con datos diarios reales.

4. Resultados

4.1 Resumen general del dataset

Parámetro	Valor
Total de estaciones analizadas	168
Total de archivos parquet	19,220
Variables climáticas	PRECIP, EVAP, TMAX, TMIN
Rango temporal	1941 – 2025
Total de registros diarios analizados	6,392,652
Total de días faltantes	847,508 (13.3%)
Estaciones sin ningún faltante	2 (1.2%)
Estaciones con menos del 25% de faltantes	116 (69.0%)
Estaciones con 75% o más de faltantes	0 (0.0%)

4.2 Faltantes por variable (nivel de día)

La siguiente tabla presenta los resultados calculados directamente desde los 6,392,652 registros diarios reales.

Variable	Total días	Días faltantes	% Faltante	Días válidos	% Válido
PRECIP	1,598,163	10,822	0.68%	1,587,341	99.32%
EVAP	1,598,163	610,514	38.20%	987,649	61.80%
TMAX	1,598,163	113,086	7.08%	1,485,077	92.92%
TMIN	1,598,163	113,086	7.08%	1,485,077	92.92%

PRECIP es la variable con mejor cobertura histórica con solo el 0.68% de días sin dato. EVAP es la más problemática con el 38.20% de faltantes, equivalente a 610,514 días sin registro. TMAX y TMIN presentan exactamente el mismo porcentaje de faltantes (7.08%), confirmando que se miden con el mismo instrumento.

4.3 Clasificación de estaciones por nivel de faltantes

Se clasificaron las 168 estaciones en categorías según su porcentaje global de días faltantes considerando todas las variables simultáneamente.

Categoría	Estaciones	Porcentaje	Interpretación
Completa (0%)	2	1.2%	Sin ningún faltante
Baja (1-24%)	114	67.9%	Apta para modelado directo
Moderada (25-49%)	45	26.8%	Requiere imputación previa
Alta (50-74%)	7	4.2%	Uso limitado en modelado
Crítica ($\geq 75\%$)	0	0.0%	Sin estaciones en esta categoría

El 69.0% de las estaciones tienen menos del 25% de faltantes globales, lo que representa una base sólida para el entrenamiento de modelos de imputación. Ninguna estación alcanza el nivel crítico de 75%.




Figura 1. Clasificación de estaciones por nivel global de faltantes.

4.4 Heatmap de faltantes por estación y variable

El heatmap principal muestra el porcentaje de días faltantes para cada combinación estación-variable calculado desde los datos reales. Las estaciones están ordenadas de mayor a menor porcentaje de faltantes. El color verde indica datos completos y el rojo ausencia total de datos.




Figura 2. Heatmap de faltantes: estación × variable (% días sin dato).

4.5 Evolución temporal de faltantes

El heatmap temporal organiza los datos por año mostrando la evolución de la cobertura para cada variable. La gráfica de tendencia muestra con mayor claridad la mejora general de la cobertura a lo largo del tiempo para PRECIP, TMAX y TMIN, mientras que EVAP se mantiene alta durante toda la historia del dataset.




Figura 3. Heatmap temporal: año × variable (% días faltantes promedio).



Figura 4. Tendencia de faltantes por variable a lo largo del tiempo.

4.6 Patrón estacional de faltantes por mes

El análisis de faltantes por mes revela si existe algún mes del año donde sistemáticamente la cobertura es peor. La gráfica y el heatmap estacional muestran que EVAP mantiene un nivel constante de faltantes (~38%) en todos los meses sin variación estacional, lo que confirma que sus faltantes son estructurales. PRECIP muestra un ligero incremento en diciembre (1.4%) y TMAX/TMIN son muy estables durante todo el año (~7%).




Figura 5. Patrón estacional de faltantes por mes y variable.




Figura 6. Heatmap estacional mes × variable con valores anotados (%).

4.7 Análisis de rachas de faltantes consecutivos

Una racha es una secuencia de días consecutivos sin dato. Este análisis distingue entre faltantes dispersos, fáciles de imputar con interpolación, y rachas largas que requieren estrategias más robustas.

Variable	Racha mediana	Racha máxima	Interpretación
PRECIP	31 días	1,461 días (~4 años)	Mayoría de rachas cortas
EVAP	1,307 días (~3.6 años)	18,389 días (~50 años)	Rachas estructuralmente largas
TMAX	26 días	8,825 días (~24 años)	Rachas moderadas a largas
TMIN	26 días	8,825 días (~24 años)	Idéntico a TMAX

La racha mediana de EVAP de 1,307 días (~3.6 años) confirma que sus faltantes son estructurales. PRECIP con mediana de 31 días y TMAX/TMIN con 26 días son mucho más manejables para imputación.

Distribución de Rachas Máximas de Faltantes por Variable




Figura 7. Distribución de rachas máximas de faltantes por variable.

4.8 Correlación de faltantes entre variables

El heatmap de correlación muestra si cuando una variable tiene faltantes en una estación, las demás también los tienen. La correlación entre TMAX y TMIN es perfecta (1.00), confirmando su origen instrumental común. EVAP tiene correlación baja con PRECIP (0.25) y con temperatura (0.23), lo que confirma que sus faltantes son independientes del resto. PRECIP y temperatura tienen correlación muy baja (0.04), indicando que sus faltantes ocurren por razones distintas.




Figura 8. Correlación de faltantes entre variables por estación.

5. Patrones de Valores Faltantes Identificados

5.1 Patrón por inactividad total de estación

Las estaciones cuyas cuatro variables presentan faltantes simultáneos en los mismos periodos corresponden a épocas de inactividad completa. La correlación entre faltantes de distintas variables es el indicador principal de este patrón. Estos periodos deben excluirse del modelado ya que no existe información de referencia disponible.

5.2 Patrón por instrumento específico fuera de servicio

EVAP presenta un patrón de faltantes independiente de las demás variables (correlación 0.23-0.25), con racha mediana de 1,307 días y máximos de hasta 50 años. Muchas estaciones nunca contaron con evaporímetro. Este patrón justifica tratar EVAP con estrategias de imputación completamente separadas de las demás variables.

5.3 Patrón de congruencia instrumental entre TMAX y TMIN

TMAX y TMIN presentan exactamente la misma cobertura (7.08% de faltantes, correlación 1.00 entre sus patrones de nulos). Esta congruencia perfecta confirma que ambas variables se registran con el mismo termómetro de máximas y mínimas. Puede aprovecharse para validación cruzada de imputaciones.

5.4 Patrón temporal de mejora en cobertura

El heatmap temporal y la gráfica de tendencia muestran una mejora general en la cobertura hacia los años más recientes para PRECIP, TMAX y TMIN, reflejando la modernización progresiva de la red del SMN. EVAP no sigue esta tendencia de forma clara debido a que sus faltantes son de naturaleza estructural.

5.5 Ausencia de patrón estacional

El análisis por mes reveló que los faltantes no tienen estacionalidad significativa en ninguna variable. EVAP mantiene ~38% en todos los meses, TMAX/TMIN ~7% y PRECIP menos del 1.4% en el peor mes (diciembre). Esto indica que los faltantes no están causados por condiciones climáticas estacionales sino por factores operativos o instrumentales.

6. Recomendaciones

- Priorizar para entrenamiento de modelos de imputación las 116 estaciones con menos del 25% de faltantes globales, que representan el 69% de la red.

- Diseñar un modelo de imputación específico para EVAP independiente del modelo para temperatura y precipitación, dado que sus faltantes son estructuralmente largos y de naturaleza diferente.
- Para PRECIP, TMAX y TMIN aplicar interpolación temporal para rachas cortas (menores a 30 días) y métodos basados en estaciones vecinas para rachas más largas.
- Aprovechar la correlación perfecta entre TMAX y TMIN para validación cruzada de imputaciones.
- Excluir del modelado los periodos con faltantes simultáneos en todas las variables, que corresponden a inactividad total de la estación.
- Usar datos de años recientes (mayor cobertura) como conjunto de validación y datos históricos como conjunto de entrenamiento con imputación previa.

7. Conclusiones

El análisis de valores faltantes sobre los 6,392,652 registros diarios reales reveló que la base de datos hidrometeorológica de Sinaloa tiene un nivel general de faltantes del 13.3%, con diferencias importantes entre variables. PRECIP es la variable más completa con 0.68% de faltantes, mientras que EVAP es la más problemática con 38.20%.

La clasificación de estaciones muestra que el 69% de la red tiene menos del 25% de faltantes globales y ninguna estación alcanza el nivel crítico de 75%, lo que representa una base sólida para el modelado. Se identificaron cinco patrones distintos de valores faltantes, siendo el más relevante la ausencia de estacionalidad, lo que confirma que los faltantes son de origen operativo o instrumental y no climático.

El análisis de rachas confirma que EVAP tiene rachas medianas de 3.6 años, lo que implica que sus faltantes son estructurales y no puntuales. PRECIP y temperatura tienen rachas manejables con medianas de 26 a 31 días. Estos resultados orientan directamente la selección de métodos de imputación para las etapas siguientes del proyecto de reconstrucción.

8. Entregables

Entregable	Descripción
analisis_valores_faltantes.ipynb	Notebook con 17 celdas de análisis completo desde parquet
heatmap_faltantes_estacion_variable.png	Figura 2 — Heatmap estación × variable
heatmap_faltantes_temporal.png	Figura 3 — Heatmap temporal año × variable

tendencia_faltantes_temporal.png	Figura 4 — Tendencia temporal de faltantes
patron_estacional_faltantes.png	Figura 5 — Patrón estacional por mes
heatmap_estacional_faltantes.png	Figura 6 — Heatmap estacional mes × variable
rachas_faltantes_por_variable.png	Figura 7 — Distribución de rachas máximas
correlacion_faltantes_variables.png	Figura 8 — Correlación de faltantes entre variables
reporte_analisis_faltantes.docx	Este reporte en formato Word